

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
INSTITUTO DE INFORMÁTICA
CURSO DE CIÊNCIA DA COMPUTAÇÃO

HENRIQUE TREIN
MATEUS POLETTO
JOÃO GABRIEL WENDT

**Upright: Sistema de Monitoramento
Postural em Tempo Real por Visão
Computacional**

Relatório do Projeto Integrador

:

Porto Alegre
2026

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

Reitora: Prof^a. Marcia Cristina Bernardes Barbosa

Vice-Reitor: Prof. Pedro de Almeida Costa

Pró-Reitora de Graduação: Prof^a. Nádyá Pesce da Silveira

Diretor do Instituto de Informática: Prof. Luciano Paschoal Gaspar

Coordenador do Curso de Ciência de Computação: Prof. Álvaro Freitas Moreira

Bibliotecário-chefe do Instituto de Informática: Alexsander Borges Ribeiro

RESUMO

O sedentarismo e o trabalho prolongado em frente a computadores têm intensificado a prevalência de desvios posturais na população, com consequências que variam de desconforto musculoesquelético a lesões crônicas. Este trabalho descreve o desenvolvimento do sistema **Upright**, uma solução de monitoramento postural em tempo real baseada em visão computacional. O sistema utiliza a biblioteca MediaPipe com o modelo BlazePose para extrair marcos anatômicos do corpo humano a partir da webcam do computador e calcular métricas de desvio postural. São monitorados quatro indicadores: assimetria horizontal dos ombros, desvio lateral do pescoço, protrusão anterior da cabeça e inclinação lateral da cabeça. Uma pontuação global é calculada por quadro como média aritmética dos escores individuais. O sistema emite alertas audiovisuais em tempo real (sonoros e setas visuais indicativas) via HUD sobreposto ao vídeo da câmera, registra sessões em banco de dados SQLite de maneira local, é personalizável e gera relatórios HTML para acompanhamento. A validação foi conduzida com anotação manual, por um médico, de 99 quadros obtidos entre usos de 4 usuários diferentes, alcançando acurácia de 88,9% e *recall* de 60,9% para detecção de má postura.

Palavras-chave: monitoramento postural. visão computacional. MediaPipe. ergonomia computacional.

SUMÁRIO

1 INTRODUÇÃO	5
2 DESENVOLVIMENTO.....	7
2.1 Fundamentação Teórica	7
2.1.1 Ergonomia e Desvios Posturais.....	7
2.1.2 Estimação de Pose.....	7
2.1.3 Suavização por Média Móvel Exponencial.....	7
2.1.4 Gasto Energético e Pegada de Carbono	8
2.2 Metodologia	8
2.2.1 Elicitação de Requisitos	8
2.2.2 Ferramentas e Tecnologias.....	9
2.3 Implementação	9
2.3.1 Arquitetura do Sistema.....	9
2.3.2 Calibração	10
2.3.3 Perfis de Rigidez	11
2.3.4 Banco de Dados e Relatórios	11
3 RESULTADOS E DISCUSSÕES	12
3.1 Protocolo de Validação.....	12
3.2 Métricas de Desempenho	12
3.3 Análise Crítica	13
3.3.1 Análise de Desempenho (Benchmarking).....	15
4 CONCLUSÕES	18
REFERÊNCIAS	20

1 INTRODUÇÃO

A dor cervical é um problema de saúde pública global, tendo afetado cerca de 203 milhões de pessoas em 2020, com projeção de atingir 269 milhões até 2050 (um aumento de 32,5%) no mundo (GBD 2021 Neck Pain Collaborators, 2024). Atualmente, a dor cervical é classificada como a 11ª maior causa de incapacidade entre 369 doenças e lesões avaliadas (GBD 2021 Neck Pain Collaborators, 2024). O principal fator atribuído a esse crescimento expressivo é o uso intensivo de computadores, notebooks e celulares (DEMISSIE; BAYIH; DEMMELASH, 2024; MOHAMMADIAN; MOLLASOSEINI; NAGHIBZADEH-TAHAMI, 2025).

O impacto econômico e social dessa condição é alarmante. Nos Estados Unidos, distúrbios musculoesqueléticos ocupacionais custam entre US\$ 45 e 54 bilhões anuais em custos médicos e absenteísmo (DEMISSIE; BAYIH; DEMMELASH, 2024). Em adição, a prevalência de dor cervical crônica entre trabalhadores espanhóis foi estimada em 12,3%, os quais perderam pelo menos 7 dias de trabalho ao ano por esse fator (MESAS et al., 2014).

Nesse cenário, a adoção massiva de rotinas de trabalho em frente a computadores tem contribuído para o aumento expressivo de queixas relacionadas à postura inadequada (YIP; CHIU; POON, 2008). A flexão crônica da cabeça para frente impõe cargas progressivamente maiores sobre a coluna cervical: estudos estimam que a carga cresce de cerca de 12 kg a 15° de inclinação para aproximadamente 27 kg a 60° de flexão (HANSRAJ, 2014). Similarmente, a assimetria dos ombros e a inclinação lateral do pescoço são indicadores de fadiga postural com potencial de evoluir para lesões estruturais (MCATAMNEY; CORLETT, 1993).

Sistemas atuais de avaliação postural exigem equipamentos especializados e caros, ambientes controlados ou a presença de profissionais de saúde, o que os torna inacessíveis para uso cotidiano. Este trabalho descreve o projeto **Upright**, cujo objetivo central é fornecer um sistema de monitoramento postural em tempo real que:

- detecte desvios posturais a partir da webcam do próprio computador, sem marcadores físicos;
- forneça feedback visual e sonoro de correção imediata ao usuário via HUD;
- registre o histórico postural e preferências do usuário em um banco de dados local;
- gere relatórios de desempenho e contabilize o consumo energético da aplicação;

- seja acessível economicamente;
- seja de fácil interação.

2 DESENVOLVIMENTO

2.1 Fundamentação Teórica

2.1.1 Ergonomia e Desvios Posturais

A ergonomia computacional estuda a interação entre o trabalhador e o ambiente digital de modo a prevenir lesões e promover bem-estar. A norma ISO 11226:2000 (International Organization for Standardization, 2000) define critérios para a avaliação de posturas de trabalho e estabelece limites angulares para a simetria corporal. O método **RULA** (Rapid Upper Limb Assessment) (MCATAMNEY; CORLETT, 1993) sistematiza a avaliação de risco em membros superiores por meio de escores angulares ponderados, penalizando qualquer flexão lateral do pescoço. As diretrizes da SOSORT (NEGRINI et al., 2018) reforçam a relevância da assimetria de ombros e de tronco como sinal clínico na avaliação postural. O estudo de Kapandji (KAPANDJI, 2000) sobre fisiologia articular descreve a amplitude de movimento da coluna cervical, faixa anatômica que serve de referência para os limiares adotados nos perfis do sistema, que variam de 5 (rigoroso) a 15 (relaxado) para o limite da inclinação lateral da cabeça.

2.1.2 Estimação de Pose

O MediaPipe é uma biblioteca de visão computacional desenvolvida pelo Google que disponibiliza pipelines de percepção otimizados para dispositivos de borda. O modelo BlazePose estima 33 landmarks do corpo humano a partir de imagens monoculares RGB com latência compatível com processamento em tempo real. Cada landmark é acompanhado de um escore de visibilidade, que o Upright utiliza para descartar estimativas com baixa confiança.

2.1.3 Suavização por Média Móvel Exponencial

Winter (WINTER, 2009) estabelece a filtragem de ruído cinemático como etapa mandatória em aplicações de biomecânica. O Upright aplica EMA (Média Móvel

Exponencial) a cada métrica calculada:

$$\hat{s}_t = \alpha \cdot s_t + (1 - \alpha) \cdot \hat{s}_{t-1}$$

onde s_t é o escore bruto do quadro atual, $\hat{s}_{t-1}$ o escore suavizado anterior e $\alpha \in (0, 1)$ o fator de suavização configurável. Isso evita alertas causados por tremores.

2.1.4 Gasto Energético e Pegada de Carbono

A inferência contínua de modelos de aprendizado de máquina gera custos computacionais mensuráveis em consumo energético e emissões de carbono. O Upright integra a biblioteca CodeCarbon (CodeCarbon Team, 2021) para mensuração automática do consumo energético por sessão.

2.2 Metodologia

2.2.1 Elicitação de Requisitos

Os requisitos funcionais e não funcionais foram levantados por meio de três abordagens complementares:

1. **Pesquisa bibliográfica:** revisão da literatura sobre métodos de avaliação postural para definir as métricas e limiares clínicos adotados nos perfis do sistema;
2. **Observação iterativa:** testes contínuos durante o desenvolvimento com o sistema em uso real, identificando falsos positivos e negativos, exceções e ajustando sensibilidades;
3. **Entrevistas informais:** feedback de usuários sobre a usabilidade da interface, frequência de alertas, conteúdo dos relatórios e outros aspectos.

Alguns dos requisitos do projeto incluem: detecção de desvios posturais em tempo real, alertas de áudio, alertas visuais, feedback visual de correção, autenticação de usuário, persistência de sessões, geração de relatórios HTML, filtros de privacidade, modo de pausa, janela de tutorial de uso, modo de calibração personalizado, operação em CPU sem GPU dedicada, formato de vídeo com menor latência, suporte a perfis de rigidez configuráveis (Relaxado, Normal, Rigoroso) e consumo energético monitorado.

2.2.2 Ferramentas e Tecnologias

Tabela 2.1 – Principais tecnologias do sistema Upright

Tecnologia	Versão	Finalidade
Python	3.10+	Linguagem principal da aplicação
Conda	23.x+	Gerenciamento de pacotes e ambientes virtuais isolados
MediaPipe Tasks	0.10+	Estimação de pose (BlazePose) e segmentação
OpenCV	4.x	Captura de câmera, renderização do HUD
SQLite	3.x	Persistência local de sessões e calibrações
Tkinter	built-in	Janelas de autenticação e configuração
CodeCarbon	2.x	Rastreamento de emissões de CO ₂

2.3 Implementação

2.3.1 Arquitetura do Sistema

O Upright é organizado em módulos Python com responsabilidades bem definidas, conforme descrito na Tabela 2.2. A organização estrutural dos componentes da aplicação e as dependências entre os diferentes módulos desenvolvidos são apresentadas no diagrama de pacotes ilustrado na Figura 2.1.




Figura 2.1 – Diagrama de pacotes do sistema Upright

O relacionamento entre as entidades do sistema no banco de dados local, é detalhada no diagrama de classes disposto na Figura 2.2.

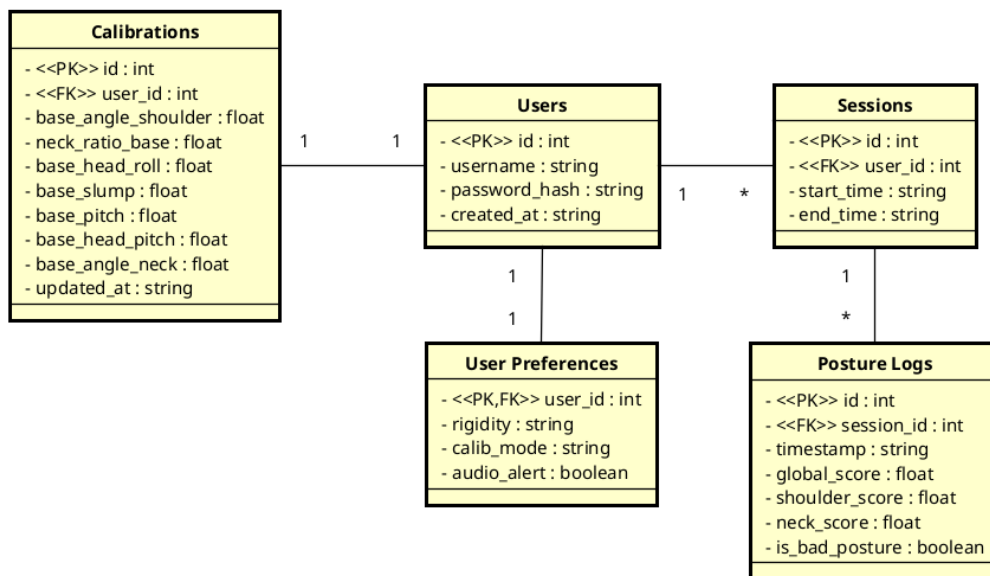


Figura 2.2 – Diagrama de classes do sistema Upright

Tabela 2.2 – Módulos da aplicação Upright

Módulo	Responsabilidade
main.py	Loop principal: captura, inferência, lógica de alertas, log
posture.py	Cálculo dos ângulos posturais e escores individuais
hud.py	Renderização do HUD sobre o quadro de vídeo
config.py	Parâmetros globais, estado EMA, histórico postural
db.py	Operações SQLite: sessões, calibração, preferências, log
auth_window.py	Interface Tkinter de autenticação
config_window.py	Interface Tkinter de configuração de perfil
privacy.py	Segmentação e substituição de fundo
generate_report.py	Geração de relatório HTML com histórico da sessão

2.3.2 Calibração

Antes do uso, o sistema permite que o usuário assuma uma postura ereta de referência e pressione C para capturar os ângulos base. Os valores são persistidos no banco de dados e carregados automaticamente nas sessões seguintes. Alternativamente, o usuário pode optar por padrões do sistema. Os valores padrão adotados correspondem a uma postura considerada adequada, com ângulos de ombro, pescoço e inclinação da cabeça iguais a 0°, além de valores empíricos de 1.22 para o desabamento vertical e -0.05 para a

inclinação do queixo.

2.3.3 Perfis de Rigidez

O sistema oferece três perfis configuráveis que ajustam simultaneamente os limiares máximos e o limiar de disparo de alerta:

Tabela 2.3 – Parâmetros dos perfis de rigidez

Perfil	θ_{limiar}	θ_{ombro}	$\theta_{\text{pescoço}}$	$\theta_{\text{cabeça}}$
Relaxado	0,35	15	25	15
Normal	0,50	10	15	8
Rigorouso	0,60	5	8	5

2.3.4 Banco de Dados e Relatórios

O banco SQLite mantém cinco tabelas: `users`, `calibrations`, `user_preferences`, `sessions` e `posture_logs`. A cada intervalo configurável de quadros, o sistema registra a média dos escores do intervalo em `posture_logs`. O módulo `generate_report.py` consulta esses dados via SQL e gera um arquivo HTML com gráficos de linha do escore histórico, estatísticas descritivas, equivalências de impacto ambiental do consumo energético medido pelo CodeCarbon e as referências clínicas.

3 RESULTADOS E DISCUSSÕES

3.1 Protocolo de Validação

Para avaliar o desempenho do sistema em condições reais de uso, foi conduzido um protocolo de testes envolvendo 4 usuários diferentes em frente ao computador. Foram obtidos 99 quadros de posturas extraídos em intervalos regulares ao longo das sessões através de um script automatizado. Cada quadro coletado foi anotado manualmente por um médico convidado, com um rótulo binário correspondente ao gabarito real: 1 para situações de boa postura ou 0 para cenários de má postura, mapeando em conjunto o escore numérico global gerado pelo Upright naquele mesmo instante. O conjunto de dados resultante apresenta um desequilíbrio natural de classes, refletindo o comportamento habitual dos usuários durante o uso monitorado:




Figura 3.1 – Proporção de classes pós-anotação

3.2 Métricas de Desempenho

Utilizando o limiar padrão estabelecido para o modo de operação Normal, as métricas de classificação alcançadas pelo sistema Upright estão consolidadas na Tabela 3.1.

Tabela 3.1 – Desempenho do Upright na validação manual (99 quadros)

Métrica	Valor
Acurácia	88,9%
F1-Score (boa postura, class.=1)	93,1%
F1-Score (má postura, class.=0)	71,8%
F1-macro	82,4%
Precision (má postura)	87,5%
Recall (má postura)	60,9%

A matriz de confusão obtida a limpo a partir do cruzamento entre as predições do sistema e o gabarito humano está disposta na Tabela 3.2.

Tabela 3.2 – Matriz de confusão — limiar = 0,5 (modo Normal)

		Predição do sistema	
		Má (0)	Boa (1)
Anotação humana (Gabarito)	Má (0)	14 (VN)	9 (FP)
	Boa (1)	2 (FN)	74 (VP)

3.3 Análise Crítica

Os nove casos de Falso Positivo mapeados, situações em que os quadros foram anotados manualmente como má postura, porém o sistema manteve a classificação como satisfatória, evidenciam que alguns desvios não são capturados plenamente pela aplicação. Isso pode ocorrer devido à adoção da média aritmética simples na pontuação global, gerando um efeito de diluição onde um componente crítico de desvio postural é camuflado se os demais parâmetros anatômicos adjacentes permanecerem com escores próximos de 1,0. Por outro lado, os dois casos computados como Falso Negativo ilustram cenários em que o algoritmo gerou alertas de má postura frente a posições que o avaliador humano julgou como aceitáveis. É importante destacar que a incidência de erros da aplicação é altamente sensível ao limiar de corte adotado. Como o Upright gera um escore contínuo entre 0,0 e 1,0, a classificação binária depende de uma fronteira rígida, fixada em 0,50 para refletir o modo "Normal". Grande parte das classificações incorretas obteve pontuações muito próximas a essa margem de 50%. Portanto, um leve ajuste nesse limiar poderia

alterar significativamente o volume e a proporção entre falsos positivos e falsos negativos detectados.

A distribuição quantitativa desses escores está ilustrada nos diagramas indicados abaixo.




Figura 3.2 – Histograma de distribuição do score por classe




Figura 3.3 – Boxplot de dispersão do score por classe

Limitações adicionais identificadas:

- **Dataset restrito:** A amostragem de 99 quadros avaliada sobre 4 usuários restringe o potencial de generalização da solução.
- **Desbalanceamento de classes:** A métrica de acurácia global (88,9%) encontra-se

inflada pelo peso da classe majoritária (boa postura). A métrica clínica que dita a eficácia preventiva real do sistema é o *recall* de má postura, consolidado em 60,9%.

- **Webcam:** O posicionamento frontal e unidirecional da câmera impossibilita o rastreamento completo do tronco (como lombar e coluna).
- **Sensibilidade ao ambiente:** Ambientes de baixa luminosidade de fundo ou forte contra-iluminação degradam a precisão de extração geométrica do modelo utilizado.

3.3.1 Análise de Desempenho (Benchmarking)

Para garantir que o sistema funcione bem em tempo real, testamos diferentes formatos de imagem da webcam (YUYV e MJPG) e opções de processamento (somente o processador/CPU, a placa de vídeo integrada e a placa de vídeo dedicada). A Figura 3.4 apresenta uma visão geral comparativa do consumo de CPU em todos os cenários avaliados.




Figura 3.4 – Visão geral do consumo de CPU por cenário e formato de vídeo.

Embora se esperasse que o vídeo sem compressão (YUYV) exigisse menos do computador, o formato comprimido (MJPG) consumiu menos CPU de forma consistente. Como ilustrado na Figura 3.5, no cenário utilizando apenas o processador, o formato MJPG atingiu 17,1% de uso de CPU, frente a 19,4% do YUYV. Isso acontece porque o formato YUYV requer a transferência de uma quantidade massiva de dados sem compressão, o que sobrecarrega o barramento interno do sistema e obriga o processador a trabalhar intensamente na recepção contínua desses dados, enquanto o MJPG transmite imagens já comprimidas na origem.




Figura 3.5 – Comparação de consumo de CPU no cenário exclusivo de processador.

Quanto ao hardware, utilizar a placa de vídeo integrada (Iris Xe) provou-se a opção mais eficiente. A Figura 3.6 demonstra como o decodificador de hardware absorve grande parte da carga (56–59% de uso da GPU), aliviando consideravelmente o processador e aumentando a taxa de quadros, reduzindo o uso da CPU para 13,9% no melhor caso (MJPG).




Figura 3.6 – Uso de CPU e GPU no processamento com a placa de vídeo integrada.

Curiosamente, ativar a placa de vídeo dedicada (NVIDIA MX450), que costuma ser mais potente, acabou elevando o uso da CPU para mais de 22%, apesar de a GPU rodar de forma eficiente com apenas 39% de carga, como evidenciado na Figura 3.7. Supõe-se que esse fenômeno ocorra devido ao PRIME offload: como a placa dedicada não é conectada diretamente à tela nos laptops, os quadros processados precisam ser constantemente

copiados de volta para a memória principal, gerando um overhead substancial na CPU que anula a vantagem do seu poder de processamento.




Figura 3.7 – Uso de CPU e GPU no processamento com a placa de vídeo dedicada, sugerindo um possível overhead

4 CONCLUSÕES

O sistema Upright demonstrou que é viável detectar desvios posturais em tempo real usando apenas uma webcam comum, sem a necessidade de equipamentos caros ou marcadores físicos. Na validação, conduzida com 99 quadros de 4 usuários diferentes e anotada manualmente por um profissional da saúde, o algoritmo atingiu uma acurácia de 88,9%. Um indicador essencial desse resultado é o F1-macro de 82,4%: como o nosso conjunto de testes possuía muito mais exemplos de “boa postura” do que de “má postura”, o F1-macro é fundamental porque avalia o sistema dando o mesmo peso para as duas classes, garantindo que a alta taxa de acertos nas posturas corretas não mascare as falhas de detecção. Além disso, o *recall* (sensibilidade) para má postura ficou em 60,9%. Na prática, isso significa que o sistema alerta o usuário sobre cerca de 60% das posições de risco reais. Esse valor reflete um bom equilíbrio no limiar de detecção (0,5), pois a ferramenta intervém o suficiente para corrigir a ergonomia, mas evita ser sensível demais a ponto de gerar alertas incômodos a cada movimento. Cabe observar também um fator inerente ao protocolo de validação adotado: os usuários nem sempre estiveram 100% atentos para obedecer aos feedbacks de correção do sistema. Caso houvesse uma pronta resposta aos alertas, a permanência em posturas inadequadas seria interrompida mais rapidamente, evitando o registro prolongado de desvios e reduzindo a captação de quadros classificados como má postura, o que muito provavelmente teria elevado as nossas métricas de desempenho. Assim, os resultados confirmam que a solução atinge seus objetivos como uma ferramenta de baixo custo para o monitoramento diário.

As principais contribuições do projeto são:

- implementação de quatro métricas posturais clinicamente referenciadas sobre saídas 2D do MediaPipe;
- geração de relatórios descritivos para acompanhamento da saúde postural;
- calibração personalizada por usuário com persistência em banco de dados;
- integração de rastreamento de consumo energético (CodeCarbon);
- análise de desempenho de diferentes formatos de imagem da webcam (YUYV e MJPG);
- análise de diferentes opções de processamento (somente CPU, GPU integrada e GPU dedicada).

Trabalhos futuros podem explorar: (1) ponderação diferenciada dos componentes

posturais em vez de média simples, priorizando métricas de maior relevância clínica e melhorando o limiar de *recall*; (2) expansão do dataset de validação com mais usuários, ambientes, iluminação, itens de vestuário e posições da câmera; (3) identificação de diferentes posturas em frente à câmera, como o uso de dois ou mais monitores; (4) integração de aprendizado por reforço para personalizar a avaliação e acompanhar a evolução do usuário.

REFERÊNCIAS

CodeCarbon Team. **CodeCarbon: Estimate and Track Carbon Emissions from Machine Learning Computing**. 2021. Disponível em: <<https://github.com/mlco2/codecarbon>>.

DEMISSIE, B.; BAYIH, E. T.; DEMMELASH, A. A. A systematic review of work-related musculoskeletal disorders and risk factors among computer users. **Heliyon**, v. 10, p. e25075, jan. 2024.

GBD 2021 Neck Pain Collaborators. Global, regional, and national burden of neck pain, 1990–2020, and projections to 2050: a systematic analysis of the global burden of disease study 2021. **The Lancet Rheumatology**, v. 6, n. 3, p. e142–e155, mar. 2024.

HANSRAJ, K. K. Assessment of stresses in the cervical spine caused by posture and position of the head. **Surgical Technology International**, San Francisco, v. 25, p. 277–279, nov. 2014.

International Organization for Standardization. **ISO 11226:2000: Ergonomics — Evaluation of static working postures**. Genebra, 2000. No Brasil: ABNT NBR ISO 11226.

KAPANDJI, A. I. **Fisiologia articular: tronco e coluna vertebral**. 6. ed. Rio de Janeiro: Guanabara Koogan, 2000. v. 3.

MCATAMNEY, L.; CORLETT, E. N. RULA: a survey method for the investigation of work-related upper limb disorders. **Applied Ergonomics**, v. 24, n. 2, p. 91–99, 1993.

MESAS, A. E. et al. The association of chronic neck pain, low back pain, and migraine with absenteeism due to health problems in spanish workers. **Spine (Phila Pa 1976)**, v. 39, n. 15, p. 1243–1253, 2014.

MOHAMMADIAN, M.; MOLLAHOSEINI, S.; NAGHIBZADEH-TAHAMI, A. Musculoskeletal disorders among office workers: prevalence, ergonomic risk factors, and their interrelationships. **Scientific Reports**, v. 15, n. 45425, p. 1–12, nov. 2025.

NEGRINI, S. et al. 2016 SOSORT guidelines: orthopaedic and rehabilitation treatment of idiopathic scoliosis during growth. **Scoliosis and Spinal Disorders**, v. 13, p. 3, 2018.

WINTER, D. A. **Biomechanics and Motor Control of Human Movement**. 4. ed. Hoboken: John Wiley & Sons, 2009.

YIP, C. H. T.; CHIU, T. T. W.; POON, A. T. K. The relationship between head posture and severity and disability of patients with neck pain. **Manual Therapy**, Edinburgh, v. 13, n. 2, p. 148–154, maio 2008.